Analyse de 5000 parties d'échecs personnelles jouées de 2018 à 2026

Data Storytelling

Réalisé par :

Hugues LUROIS

ENSAE Paris - 3A

2025/2026

1. Contexte et dataset

1.1 Naissance de l'idée

Passionné du jeu d'échecs, c'est tout naturellement que j'ai cherché à faire de cette passion le sujet de mon projet de Data Storytelling. Mais était-ce vraiment pertinent dans le cadre de cet exercice ?

J'ai tout de suite pensé que oui. J'avais, avant même le début du projet, pleinement conscience de la richesse informationnelle que pouvait contenir une partie d'échecs. Le PGN d'une partie, c'est-à-dire la notation échiquéenne permettant de rejouer intégralement une partie, permet d'extraire des données sur le type d'ouverture, la longueur de la partie, le vainqueur, les cases les plus mobilisées... Ce qui m'a poussé à croire que rien qu'en disposant de milliers de PGN, j'avais déjà la matière pour réaliser un nombre de visualisations incalculables.

Je suis donc parti dans cette voie. Je me suis orienté vers des datasets publics contenant des centaines de milliers de parties jouées sur les plateformes chess.com ou encore lichess. Entre le PGN, le classement elo, la date ou encore la précision de la partie, je savais que c'était une piste prometteuse. J'avais également envisagé étudier des parties de grand maître comme Carlsen, Kasparov ou encore Karpov.

Puis j'ai réalisé que je pouvais en réalité faire ce même travail mais sur mes propres parties. En effet, en m'intéressant au sujet, je suis assez rapidement tombé sur le site chessinsights.xyz qui permet d'exporter l'intégralité de l'historique de parties d'un compte Chess.com au format CSV. En comprenant qu'étudier ses propres parties pouvait conférer une forte dimension « Storytelling » au projet, je n'ai pas hésité et j'ai opté pour ce dataset.

1.2 Le dataset

Le fichier CSV exporté contient 5 093 parties jouées entre le 20 août 2018 et le 9 février 2026. Chaque ligne regroupe 17 variables couvrant l'ensemble des métadonnées d'une partie :

Variables	Description
userRating / opponentRating	Classement ELO des deux joueurs avant la partie
userAccuracy / opponentAccuracy	Précision calculée par Chess.com (de 0 à 100)
result / outcome	Résultats de la partie (Victoire/Défaite/Nulle) + Fin de partie (Temps insuffisant, abandon, échecs et mat..)
opening	Nom complet de l'ouverture jouée
pgn	Notation complète de la partie en format PGN
timeClass	Cadence : blitz (3 min), rapide (10 min), bullet (1 min)
moveCount	Nombre total de demi-coups joués
date / startTime / endTime	Horodatage complet de la partie

1.3 Objectifs du projet

Disposer de 5 093 parties ne suffit pas à faire du data storytelling. Cela nécessite d'avoir une idée très précise de ce que l'on souhaite mettre en lumière. Je ne souhaitais pas me contenter de décrire des statistiques que l'on peut obtenir directement depuis une interface chess.com (Elo, fréquence de jeu, nombre de parties...). L'objectif était justement de dépasser cette lecture descriptive.

C'est pourquoi, chaque visualisation a été pensée comme une réponse à une question précise, avec l'idée d'apporter un éclairage que le joueur ne peut pas obtenir en parcourant simplement son historique. Autrement dit, il ne s'agissait pas de montrer des données parce qu'elles existent, mais parce qu'elles en disent long sur le joueur qu'elles concernent.

Disposant d'un grand nombre d'idées de visualisations, il a fallu faire un choix basé sur la pertinence mais aussi sur l'accessibilité pour un individu non connaisseur. Quatre angles d'analyse sont alors ressortis. D'abord, une première visualisation intuitive semblait incontournable et primordiale. Je fais référence à la progression dans le temps. Comment mon niveau a-t-il évolué sur plusieurs années, et peut-on identifier des périodes marquantes en comparant la progression sur chacune des cadences ? Cette visualisation permet aussi aux lecteurs de se faire un avis sur le niveau du joueur étudié. Ensuite, ce qui caractérise un joueur d'échecs est en premier lieu son répertoire d'ouvertures : quelles lignes sont réellement jouées, avec quelle régularité, et quels résultats ? Troisièmement, j'ai jugé qu'une visualisation sophistiquée portant sur la fréquence d'utilisation des cases pouvait être réellement intéressante et pouvait permettre de raconter une histoire. Enfin, mon esprit de statisticien m'a conduit à observer un phénomène statistique assez intéressant concernant la distribution des parties selon leur nombre de coups et j'ai donc voulu le mettre en lumière. Cette dernière visualisation est d'autant plus intéressante qu'elle présente une caractéristique de mon jeu.

Ces quatre axes convergent vers une même problématique : Est-ce que l'analyse de 5 000 parties d'échecs d'un joueur amateur permet, même pour un public non initié, de faire ressortir un style de jeu, ainsi que ses forces et ses faiblesses ?

1.4 Public visé

Ce projet s'adresse à deux types de lecteurs distincts. D'un côté, les joueurs d'échecs, qu'ils soient débutants ou confirmés, qui trouveront dans ces visualisations une lecture familière. Les ouvertures, l'elo, le contrôle du centre sont des concepts qu'ils maîtrisent et qu'ils sauront apprécier. De l'autre, un public non initié aux échecs, qui n'a pas besoin de connaître le nom d'une ouverture pour comprendre qu'un joueur en privilégie systématiquement certaines, ou pour lire qu'il gagne davantage les parties courtes que les longues. Il est bien sûr préférable de connaître les règles du jeu mais même sans cela, la lecture des visualisations est intéressante.

Ce double public a été une contrainte de conception. Chaque visualisation est accompagnée d'un texte explicatif qui contextualise les données sans présupposer de connaissances échiquéennes. Les termes techniques (ELO, cadence, ouverture) y sont définis au premier usage. L'objectif était que le projet soit pleinement lisible par quelqu'un qui n'a jamais touché un échiquier, tout en restant suffisamment riche pour intéresser un joueur averti.

1.5 Choix du format

Le projet se présente sous la forme d'un site web multi-pages, hébergé sur GitHub Pages. Ce choix s'est imposé naturellement. La nature interactive des visualisations (échiquier jouable, filtres dynamiques, infobulles) nécessitait un environnement web. Un site est par ailleurs accessible depuis n'importe quel navigateur, sur ordinateur comme sur téléphone, sans installation, ce qui facilite la diffusion et garantit une lecture intuitive quel que soit le support et pour tout public.

Concernant la structure, j'ai délibérément choisi de séparer les visualisations en plusieurs pages plutôt que de tout regrouper sur une unique page défilante. La raison est simple : chaque visualisation aborde un angle d'analyse bien distinct, et je trouvais qu'elles méritaient chacune leur propre espace. Les rassembler sur une même page aurait produit quelque chose d'ennuyeux et peu engageant, où l'on passe d'un sujet à l'autre sans vraiment savoir pourquoi. La séparation permet à chaque visualisation de raconter sa propre histoire sans que cela soit trop long.

2. Visualisation de la progression dans le temps

2.1 Objectif

La première visualisation aborde la question la plus naturelle pour tout joueur : ai-je progressé ? Deux indicateurs complémentaires sont mobilisés. L'elo mesure le niveau relatif dans la communauté échiquéenne. C'est un score dynamique qui augmente lorsqu'on bat des joueurs mieux classés et diminue dans le cas contraire. La précision moyenne, calculée par Chess.com, mesure quant à elle la qualité intrinsèque des coups joués indépendamment du niveau de l'adversaire.

2.2 Choix de représentation et méthodologie

Des séries temporelles semblaient plus que naturelles. La décision de distinguer les trois cadences (blitz, rapide, bullet) par des courbes séparées plutôt qu'une courbe agrégée était primordiale. Les classements ELO sont indépendants selon la cadence sur Chess.com, les comparer directement aurait produit une courbe sans grande signification.

Pour la précision, agréger par trimestre a permis d'obtenir un juste équilibre entre lisibilité et précision. L'agrégation mensuelle produisait une courbe trop volatile. Certains mois comptent moins de 5 parties, ce qui rend la moyenne peu pertinente. Un filtre ($n \geq 5$ parties par trimestre) a été appliqué pour éliminer les points aberrants. L'axe des ordonnées pour la précision est volontairement établi entre 60% et 85% plutôt qu'entre 0% et 100%, afin

d’obtenir un graphique bien plus visible mettant davantage en valeur les variations de trimestre en trimestre.

3. Visualisation des ouvertures

3.1 Objectif

Les ouvertures constituent l'une des dimensions les plus révélatrices du style d'un joueur d'échecs. L'objectif de cette visualisation était double : montrer quelles ouvertures sont jouées et à quelle fréquence, et permettre au lecteur de naviguer interactivement dans l'arbre des coups pour observer les winrates et les fréquences associés à chaque séquence.

3.2 Choix de représentation

L'idée d'un échiquier interactif jouable s'est avérée être la représentation la plus naturelle et concluante. J’avais initialement pensé à une arborescence ou à un sunburst mais ces représentations avaient le défaut d’être illisibles au-delà de 2–3 niveaux de profondeur. L'échiquier permet de mieux visualiser les coups pour les joueurs non aguerris tout en présentant deux dimensions supplémentaires : la couleur des flèches illustre le winrate, et leur épaisseur la fréquence.

3.3 Méthodologie et choix visuel

Le PGN est le format standard de représentation des parties d'échecs. Son décodage n’est pas simple car il nécessite de maintenir l'état complet du plateau à chaque demi-coup pour résoudre les ambiguïtés de la notation algébrique.

Le décodage fonctionne comme suit pour chaque coup :

- Identification du type de pièce (P, N, B, R, Q, K) et de la case de destination. Les cas particuliers comme le petit roque et la prise en passant sont évidemment considérés.
- Résolution des ambiguïtés : si deux cavaliers peuvent aller en f3, le fichier ou la rangée de départ est précisé dans la notation
- Mise à jour du plateau en mémoire

Quant à l'arbre des coups, il est construit en parcourant les 20 premiers demi-coups de chaque partie (soit 10 coups). Un filtre de seuil minimal ($n \geq 10$ parties) est appliqué à chaque nœud de l'arbre afin de ne pas surcharger l’échiquier de flèches peu représentatives.

La palette de couleurs du winrate a été choisie pour son côté intuitif et naturel . J'aurais pu opter pour un dégradé continu mais j'ai préféré discrétiser en six paliers distincts. Cette approche, illustrée notamment dans le cours à travers l'exemple de la carte choroplèthe des États-Unis, facilite la lecture. Un dégradé continu aurait certes été plus précis, mais je n’ai pas opté pour cette option.

Les seuils ont ensuite été définis manuellement pour refléter la distribution réelle des winrate observés dans les données plutôt que des intervalles réguliers. Un winrate inférieur à 35% ou supérieur à 65% est statistiquement rare et mérite d'être visuellement distinct des cas intermédiaires. Un intervalle de 16.7% ne me paraissait en aucun cas propice dans cette situation. Le seuil de 50% apparait comme un point de bascule clair. En dessous, le coup mène à plus de défaites que de victoires et de nulles combinées, au-dessus à plus de victoires. Par ailleurs, c'est autour de ce point que la graduation est la plus petite. Les intervalles 45 - 50% et 50 - 55% sont volontairement étroits car c'est là que les différences sont les plus utiles à percevoir pour le joueur. Savoir qu'un coup mène à 47% ou 53% de victoires, c'est une information qui change réellement la décision. À l'inverse, distinguer 10% de 20% importe peu. Dans les deux cas, le coup paraît mauvais.

Enfin, un soin particulier a été apporté à l'expérience utilisateur. L'échiquier se retourne automatiquement selon la couleur sélectionnée, de sorte que le lecteur voit toujours la position de mon point de vue de joueur, c’est-à-dire les blancs en bas lorsque je joue les blancs, les noirs en bas lorsque je joue les noirs.

4. Visualisation de la Heatmap

4.1 Objectif

La heatmap cherche à répondre à la question : Quelles cases du plateau sont les plus fréquentées selon le type de pièce ? L'objectif est de faire émerger des patterns propres à chaque joueur et qui sont révélateurs de ses choix d'ouvertures et de son style de jeu.

4.2 Choix de représentation et méthodologie

La représentation par cercles proportionnels sur les 64 cases a été retenue plutôt qu'une heatmap classique. Je souhaitais que cela reste visible et le fait d’illustrer selon des couleurs rendaient cela moins clair puisque j’ai voulu représenter les pièces et faire des effets de surbrillance. L'échelle des rayons utilise une transformation en racine carrée plutôt qu'une échelle linéaire. Sans cette transformation, les cases très fréquentées (e4, d4, e5, d5) produiraient des cercles si grands qu’ils écraseraient visuellement toutes les autres cases. Cela permet de maintenir l’ordre et c’est ce que l’on recherche.

Une contrainte technique importante a conditionné la profondeur de l'analyse. L'idée initiale consistait à tracer les déplacements de chaque pièce individuelle (ex : Le fou de case blanche et le fou de case noire). Cette approche a été abandonnée. Elle nécessitait de maintenir l'état complet du plateau à chaque demi-coup pour identifier quelle pièce se déplace exactement, ce qui représentait un coût de calcul trop important au décodage. Le regroupement par type de pièce s’est donc imposé.

5. Visualisation de la distribution des parties

5.1 Objectif

La dernière visualisation explore la structure des parties. Comment se distribuent-elles selon leur longueur, et cette distribution varie-t-elle selon l'issue ? L'objectif était de faire ressortir une influence du comportement en fin de partie en enchaînant une observation statistique (les différences des deux gaussiennes) et son explication causale.

5.2 Choix de représentation et méthodologie

Deux courbes de densité ont été superposées. Une pour les victoires, une pour les défaites. Les deux distributions ne comptent pas le même nombre de parties. Il était donc primordial de travailler en pourcentage plutôt qu'en valeur afin que les deux courbes soient réellement comparables. Sans cette normalisation, la courbe des victoires aurait mécaniquement dominé celle des défaites. Non pas parce que les parties gagnées sont plus longues, mais simplement parce qu'elles sont plus nombreuses.

Les deux diagrammes circulaires sur les modalités de fin de partie complètent la visualisation en apportant une réponse qualitative à la question soulevée par la distribution. La distribution pose la question : pourquoi je perds plus les parties longues ? et les diagrammes y répondent en donnant une information sur mon jeu.

6. Limites du projet

Ce projet repose sur l'analyse des parties d'un seul joueur. Les observations sont donc propres à un style de jeu spécifique et ne sont pas généralisables. Une extension naturelle consisterait à comparer ces résultats avec d'autres profils, ce que j'ai d'ailleurs cherché à faire de mon côté mais j'ai souhaité aller à l'essentiel pour ce projet.

Concernant la heatmap, le regroupement par type de pièce plutôt que par pièce masque certaines informations. Deux cavaliers n'ont pas forcément le même rôle dans une partie, et les agréger efface cette nuance. Enfin, la visualisation de la distribution mélange toutes les cadences sur un même graphique. La distribution des parties en bullet est pourtant très différente de celle en rapide et ce choix masque des comportements potentiellement très différents selon le format.

7. Conclusion

Ce projet m'a permis de démontrer que 5 093 parties d'échecs est une base suffisamment riche pour raconter une histoire cohérente et détaillée sur un joueur. À travers quatre visualisations complémentaires, il est possible de reconstituer un profil. Je suis un joueur positionnel, au répertoire étroit mais maîtrisé, qui progresse régulièrement sur huit ans et dont le principal défaut, le manque de fairplay consistant à ne pas abandonner, est lui-même visible dans les données.

Plusieurs prolongements peuvent être envisagés. L'analyse pourrait d'abord être élargie à un volume de parties encore plus important afin de renforcer la robustesse statistique des résultats. Elle gagnerait également à être mise en perspective en comparant ces résultats avec ceux d'autres joueurs afin de distinguer ce qui relève de caractéristiques individuelles et ce qui relève de régularités plus générales. Enfin, de nouvelles visualisations pourraient venir enrichir l'analyse, par exemple en étudiant le taux de victoire selon l'heure de la journée, le différentiel elo moyen avec mon adversaire selon le résultat ou encore une analyse des erreurs identifiées par l'ordinateur selon la phase de jeu afin de déterminer à quel moment du jeu le joueur est le plus fort comparativement aux autres joueurs.